

UNIVERSITÀ DEGLI STUDI DI SALERNO
DIPARTIMENTO DI INFORMATICA

CORSO DI LAUREA MAGISTRALE IN INFORMATICA



Progetto di Statistica e Analisi dei Dati

Analisi Log di Rete per riconoscere pattern malevoli

Docenti:
Prof. Stefano Cirillo, Prof. Luigi Di Biasi

Candidato:
Antonio Margio

Contents

1	Introduzione e Dominio del Problema	2
2	Obiettivi dell'Analisi Statistica	2
3	Metodologia Statistica	2
4	Analisi Empirica e Risultati	4
4.1	Fase 1: Ispezione e Studio del Traffico Reale	4
4.1.1	Test Chi-Quadrato di Indipendenza	5
4.1.2	Regressione Lineare e Validazione dei Residui	5
4.1.3	Clustering Non Supervisionato via K-Means	6
4.2	Fase 2: Validazione e Confronto del Dataset Sintetico	7
4.2.1	Test Chi-Quadrato di Buon Adattamento (Goodness of Fit)	8
5	Conclusioni e Discussione	8
A	Appendice: Codice della Pipeline di Analisi in R	9

1 Introduzione e Dominio del Problema

Nel contesto moderno della sicurezza informatica, la protezione delle infrastrutture di rete aziendali è affidata a sistemi intelligenti che registrano continuamente ogni singola interazione. Dispositivi come Firewall e sistemi IPS/IDS (Intrusion Prevention/Detection Systems) generano flussi massivi di dati sotto forma di file di log. Analizzare questi dati non è soltanto un compito tecnico, ma una vera e propria necessità statistica: permette di estrarre pattern operativi, comprendere il comportamento degli utenti e isolare potenziali minacce prima che causino danni.

In questo scenario, il progetto affronta due sfide centrali e strettamente connesse:

1. **L'analisi del traffico reale:** Studiare i log estratti da un'infrastruttura per comprendere come le caratteristiche strutturali dei pacchetti di rete influenzino la valutazione del rischio e le conseguenti azioni automatiche di difesa.
2. **La validazione dei dati sintetici:** Valutare l'efficacia di un Large Language Model (LLM) nel generare dati artificiali. Nella cybersecurity, disporre di dati sintetici realistici è fondamentale per addestrare algoritmi di intelligenza artificiale o effettuare test di carico senza esporre informazioni aziendali sensibili o violare le normative sulla privacy.

2 Obiettivi dell'Analisi Statistica

L'indagine statistica condotta sui dataset si sviluppa attraverso obiettivi sequenziali ben definiti:

- **Esplorazione Monovariata e Bivariata:** Analizzare singolarmente le variabili quantitative principali, ovvero la lunghezza dei pacchetti (*Packet Length*) e il punteggio di anomalia assegnato dai sistemi (*Anomaly Scores*), verificandone la forma, la tendenza centrale e l'eventuale presenza di anomalie o errori nel tracciamento.
- **Studio dell'Associazione e della Relazione Lineare:** Verificare, mediante indici di associazione e modelli di regressione, se esista un legame di causa-effetto lineare tra la dimensione del dato che transita nella rete e la sua percepita pericolosità.
- **Segmentazione Logica del Traffico:** Raggruppare le osservazioni in cluster omogenei per identificare profili di traffico ricorrenti (ad esempio, traffico standard, anomalie isolate, attacchi massivi).
- **Certificazione del Dato Sintetico:** Confrontare le proprietà del dataset generato dall'LLM con quello reale mediante tecniche descrittive e test di aderenza inferenziale, verificando se l'intelligenza artificiale abbia appreso correttamente la struttura statistica sottostante.

3 Metodologia Statistica

Per raggiungere gli obiettivi prefissati, l'analisi si muove lungo tre direttrici metodologiche principali estratte dal programma del corso:

- **Analisi Descrittiva della Forma e Associazione:** Si utilizzano indici di posizione (Media, Mediana, Moda) per la tendenza centrale, e indici di associazione bivariata (Covarianza e Correlazione) per testare l'esistenza di un legame lineare tra le metriche quantitative.
- **Modellazione e Clustering:** Si applica il metodo dei Minimi Quadrati Ordinari (OLS) per stimare una retta di regressione e valutarne l'adattamento tramite lo studio dei residui. Successivamente, si impiega l'algoritmo K-Means per partizionare i dati in gruppi, basandosi sulla minimizzazione della distanza geometrica dai centroidi (valutata analiticamente tramite le metriche WCSS e BCSS).
- **Verifica Inferenziale delle Ipotesi:** Si applica il Test del Chi-Quadrato in due formulazioni distinte: il test di indipendenza (per valutare la relazione tra variabili qualitative) e il test di buon adattamento (per verificare se il dataset sintetico ricalchi fedelmente le frequenze del dataset reale).

4 Analisi Empirica e Risultati

4.1 Fase 1: Ispezione e Studio del Traffico Reale

La pipeline prende l'avvio con l'ispezione dei valori mancanti (NA). L'assenza di record nulli casuali conferma l'integrità strutturale del sistema di logging Fortigate.

L'analisi descrittiva univariata della variabile *Packet Length* evidenzia un comportamento estremamente interessante: la distribuzione non segue una forma a campana normale, ma si presenta nettamente multimodale. Come evidenziato nell'istogramma, la presenza di picchi ripetuti a frequenze specifiche riflette l'architettura stessa dei protocolli di rete, i quali utilizzano dimensioni fisse standardizzate per i pacchetti di controllo e per il transito dei carichi utili (payload).




Figure 1: Distribuzione di frequenza empirica della lunghezza dei pacchetti di rete (Dati Reali).

Al contrario, lo studio della variabile *Anomaly Scores* mostra una distribuzione uniforme e ben bilanciata su tutto l'intervallo da 0 a 100. Il diagramma a scatola e baffi (Boxplot) conferma la perfetta simmetria della metrica e l'assoluta assenza di outlier (valori anomali isolati oltre i baffi), indicando che il sistema mappa il rischio in modo continuo e standardizzato.




Figure 2: Boxplot della dispersione del punteggio di anomalia nei log reali.

Per comprendere se la dimensione del pacchetto influenzi il punteggio di rischio, è stato tracciato uno scatterplot grezzo e calcolato il coefficiente di correlazione lineare di Pearson (r_{xy}). Il valore prossimo allo zero indica l'assenza di un legame lineare diretto: un pacchetto grande non è intrinsecamente più pericoloso di uno piccolo.




Figure 3: Scatterplot bivariato grezzo tra lunghezza pacchetto e punteggio di anomalia.

4.1.1 Test Chi-Quadrato di Indipendenza

Spostando l'attenzione sulle variabili qualitative, si è voluto verificare se il tipo di protocollo (*Protocol*) condizioni l'azione intrapresa dal sistema di sicurezza (*Action Taken*). Il test del Chi-Quadrato ha restituito un p-value pari a 0.8414. Poiché questo valore è nettamente superiore alla soglia critica classica ($\alpha = 0.05$), siamo formalmente impossibilitati a rifiutare l'ipotesi nulla di indipendenza. Questo significa che le decisioni automatiche di blocco o monitoraggio vengono applicate in modo equo e uniforme, indipendentemente dal protocollo di trasporto utilizzato dal traffico.

4.1.2 Regressione Lineare e Validazione dei Residui

Per confermare l'assenza di relazioni lineari globali, è stato stimato un modello di regressione dei minimi quadrati (OLS). L'indice di determinazione D^2 (R-squared) nullo certifica che la

variabilità della dimensione dei pacchetti non spiega la variazione dei punteggi di anomalia.

Tuttavia, l'aspetto più rilevante risiede nell'analisi grafica dei residui (le distanze tra i dati reali e la retta stimata). La nuvola dei residui si dispone formando una banda rettangolare perfettamente simmetrica e densa attorno alla linea dello zero, senza mostrare imbuti o pattern geometrici. Questo comportamento (omoschedasticità) valida matematicamente il processo e dimostra che gli errori del modello sono puramente casuali e privi di distorsioni sistematiche.




Figure 4: Grafico di dispersione dei residui sperimentali del modello di regressione.

4.1.3 Clustering Non Supervisionato via K-Means

L'assenza di una relazione lineare globale non esclude la presenza di sottogruppi locali nei dati. Per mappare queste relazioni è stato applicato l'algoritmo K-Means. La scelta del numero di gruppi (k) è stata guidata dallo Scree Plot (metodo del gomito), valutando la decrescita della varianza interna (WCSS).




Figure 5: Scree Plot della varianza intra-cluster (WCSS) al variare del numero di cluster.

Il grafico mostra un netto punto di flesso (il "gomito") in corrispondenza di $k = 3$, indicando che dividere i dati in tre gruppi rappresenta il compromesso matematico ideale per massimizzare l'omogeneità interna e la separazione esterna (confermata dai valori di WCSS e BCSS stampati dalla pipeline).

L'algoritmo ha così isolato tre profili di traffico ben distinti nello spazio bivariato, come mostrato nello scatterplot colorato finale: il Cluster 1 identifica pacchetti piccoli con rischio bilanciato, il Cluster 2 intercetta pacchetti di grandi dimensioni, mentre il Cluster 3 raggruppa pacchetti di dimensioni medie. Questa segmentazione geometrica permette di semplificare l'analisi delle metriche di rete dividendo i log in categorie operative chiare.




Figure 6: Mappatura geometrica dello spazio dei log tramite partizionamento K-Means ($k = 3$).

4.2 Fase 2: Validazione e Confronto del Dataset Sintetico

La seconda parte del progetto si è focalizzata sulla validazione del dataset sintetico generato dall'LLM. Il confronto iniziale degli indici di sintesi (Minimo, Media, Massimi e Deviazioni Standard) mostra una corrispondenza quasi millimetrica tra le metriche reali e quelle artificiali.

Per analizzare visivamente l'allineamento distributivo, il boxplot di confronto affianca le distribuzioni degli score di anomalia. Le due scatole e l'estensione dei baffi risultano visivamente sovrapponibili, confermando che l'LLM ha replicato fedelmente i parametri di dispersione.




Figure 7: Boxplot comparativo della distribuzione degli Anomaly Scores.

4.2.1 Test Chi-Quadrato di Buon Adattamento (Goodness of Fit)

Per fornire una validazione inferenziale oggettiva e aderente alle slide del corso, i punteggi quantitativi continui di anomalia sono stati discretizzati in classi di frequenza equispaziate. Utilizzando le frequenze del dataset reale come base per calcolare le probabilità teoriche attese, è stato eseguito il test di buon adattamento del Chi-Quadrato sul dataset sintetico.

Il test ha confermato che le discrepanze tra le frequenze generate dall'LLM e quelle attese dal modello reale sono statisticamente irrilevanti (accettando l'ipotesi nulla di aderenza). L'intelligenza artificiale ha superato la validazione, dimostrandosi in grado di produrre dati sintetici matematicamente indistinguibili dalla popolazione reale e pronti per l'uso in contesti di simulazione sicura.

5 Conclusioni e Discussione

L'applicazione sistematica delle tecniche statistiche del corso ha permesso di completare con successo l'analisi dello scenario Fortigate. Lo studio ha dimostrato l'imparzialità dei sistemi di sicurezza rispetto ai protocolli di rete, ha escluso la presenza di relazioni lineari ingannevoli e ha isolato tre profili geometrici di traffico grazie al clustering K-Means, ottimizzato analiticamente tramite lo Scree Plot.

La validazione inferenziale condotta nella seconda fase ha certificato la qualità del dataset sintetico. L'esito positivo del test del Chi-Quadrato di buon adattamento garantisce la possibilità di adottare i dati simulati per l'addestramento e il testing delle infrastrutture di cybersecurity, eliminando i rischi di data leakage e garantendo la piena aderenza metodologica alle richieste degli standard scientifici.

A Appendice: Codice della Pipeline di Analisi in R

File: 01_preprocessing.R

```
1 # Caricamento dei dati e Pulizia
2 cat("--- step 1: CARICAMENTO E PREPROCESSING ---\n")
3
4 # Caricamento dei dataset tramite data.table
5 df_real <- fread("cybersecurity_attacks.csv")
6 df_synth <- fread("cybersecurity_sintetico.csv", sep = ",", dec
7                 = ".", strip = TRUE)
8
9 cat("--- ISPEZIONE VALORI MANCANTI (Dataset reale) ---\n")
10 na_summary <- colSums(is.na(df_real))
11 print(na_summary)
12 cat("Nota: La presenza di NA nei log di sicurezza rappresenta
13     una mancata segnalazione strutturale.\n\n")
14
15 # Pulizia e conversione manuale dei decimali per il dataset
16 # generato da LLM
17 df_synth[, 'Anomaly Scores' := as.numeric(gsub(",", ".", as.
18     character('Anomaly Scores')))]
19 df_synth[, 'Packet Length' := as.numeric(gsub(",", ".", as.
20     character('Packet Length')))]
21
22 # Allineamento del Timestamp
23 df_synth[, Timestamp := as.POSIXct(as.character(Timestamp),
24     format = "%Y-%m-%d %H:%M:%S")]
25 cat("Pre-elaborazione dei dati completata.\n\n")
```

```

1  # Analisi Descrittiva ed Inferenziale
2  cat("--- Step 2: STATISTICHE DESCRITTIVE E DISTRIBUZIONI ---\n"
      )
3
4  print(summary(df_real[, .('Packet Length', 'Anomaly Scores'))))
5
6  # Indici di Posizione Completati (Moda)
7  calcola_moda <- function(x) {
8    univ <- unique(na.omit(x))
9    univ[which.max(tabulate(match(x, univ)))]
10 }
11 cat("Moda di Packet Length:", calcola_moda(df_real$'Packet
      Length'), "\n")
12 cat("Moda di Anomaly Scores:", calcola_moda(df_real$'Anomaly
      Scores'), "\n\n")
13
14 # Statistica Descrittiva Bivariata
15 cat("--- FASE 2.1: COVARIANZA E CORRELAZIONE CAMPIONARIA ---\n"
      )
16 v_cov <- cov(df_real$'Packet Length', df_real$'Anomaly Scores',
      use = "complete.obs")
17 v_cor <- cor(df_real$'Packet Length', df_real$'Anomaly Scores',
      use = "complete.obs")
18 cat("Covarianza Campionaria:", v_cov, "\n")
19 cat("Coefficiente di Correlazione Campionario (r_xy):", v_cor,
      "\n\n")
20
21 # Visualizzazioni Univariata e Bivariate
22 print(ggplot(df_real, aes(x = 'Packet Length')) +
23       geom_histogram(bins = 50, fill = "steelblue", color = "
24         white", alpha = 0.7) +
25       labs(title = "Distribuzione Multimodale di Packet
26         Length (Dati Reali)",
27            x = "Packet Length (Bytes)", y = "Frequenza") +
28       theme_minimal())

```

```

1 # Modulo di Modellazione Statistica
2 cat("--- Step 3: MODELLAZIONE STATISTICA AVANZATA ---\n")
3
4 # Modello di Regressione Lineare Semplice
5 cat("\n[MODELLO DI REGRESSIONE LINEARE OLS]:\n")
6 mod_lineare <- lm('Anomaly Scores' ~ 'Packet Length', data = df
   _real)
7 print(summary(mod_lineare))
8
9 # Grafico dei Residui Campionari
10 plot(mod_lineare$residuals, main="Analisi dei Residui
   Campionari",
11       ylab="Residui (E_i)", xlab="Indice Osservazione", col="
   dimgray")
12 abline(h=0, col="red", lwd=2)
13
14 # 3.2 Clustering K-Means
15 cat("\n[CLUSTERING K-MEANS E SELEZIONE METRICA]:\n")
16 df_cluster <- na.omit(df_real[, .('Packet Length', 'Anomaly
   Scores')])
17 df_scaled <- scale(df_cluster)
18
19 # Scree Plot (Metodo del Gomito)
20 set.seed(123)
21 wcss <- sapply(1:10, function(k) kmeans(df_scaled, centers = k,
   nstart = 25)$tot.withinss)
22 plot(1:10, wcss, type="b", pch=19, col="darkblue",
23       xlab="Numero di Cluster (k)", ylab="WCSS", main="Scree
   Plot per la Scelta di K")
24
25 # Esecuzione Ottimale
26 kmeans_res <- kmeans(df_scaled, centers = 3, nstart = 25, iter.
   max = 50)
27 df_cluster[, Cluster := as.factor(kmeans_res$cluster)]
28
29 # Metriche di Non Omogeneit Statistica
30 cat("Somma dei Quadrati Entro i Cluster (WCSS Totale):", sum(
   kmeans_res$withinss), "\n")
31 cat("Somma dei Quadrati Tra i Cluster (BCSS):", kmeans_res$
   betweenss, "\n\n")
32
33 # Scatterplot del Cluster
34 print(ggplot(df_cluster, aes(x = 'Packet Length', y = 'Anomaly
   Scores', color = Cluster)) +
35       geom_point(alpha = 0.5) +
36       labs(title = "Segmentazione dello Spazio Bivariato via
   K-Means",
37            x = "Packet Length", y = "Anomaly Score") + theme_
   minimal())

```