

UNIVERSITÀ DEGLI STUDI DI SALERNO
DIPARTIMENTO DI INFORMATICA

CORSO DI LAUREA MAGISTRALE IN INFORMATICA



Progetto di Statistica e Analisi dei Dati

Analisi Log di Rete per riconoscere pattern malevoli

Docenti:
Prof. Stefano Cirillo, Prof. Luigi Di Biasi

Candidato:
Antonio Margio

Contents

1	Introduzione e Dominio del Problema	2
2	Obiettivi dell'Analisi Statistica	2
3	Metodologia Statistica	2
4	Analisi Empirica e Risultati	4
4.1	Fase 1: Ispezione e Studio del Traffico Reale	4
4.2	4.1 Analisi Esplorativa dei Dati (EDA) su tutte le Variabili	4
4.2.1	4.1.1 Caratterizzazione Univariata delle Variabili Categoricali	4
4.2.2	4.1.2 Caratterizzazione Univariata delle Variabili Quantitative	6
4.2.3	Test Chi-Quadrato di Indipendenza	8
4.2.4	Regressione Lineare e Validazione dei Residui	8
4.2.5	Clustering Non Supervisionato via K-Means	9
4.3	Fase 2: Validazione e Confronto del Dataset Sintetico	10
4.3.1	Test Chi-Quadrato di Buon Adattamento	11
5	Conclusioni e Discussione	11

1 Introduzione e Dominio del Problema

Nel contesto moderno della sicurezza informatica, la protezione delle infrastrutture di rete aziendali è affidata a sistemi intelligenti che registrano continuamente ogni singola interazione. Dispositivi come Firewall e sistemi IPS/IDS generano flussi di dati sotto forma di file di log. Analizzare questi dati non è soltanto un compito tecnico, ma una vera e propria necessità statistica per permettere di estrarre pattern operativi, comprendere il comportamento degli utenti e isolare potenziali minacce prima che causino danni.

In questo scenario, il progetto affronta due importanti sfide strettamente connesse:

1. **L'analisi del traffico reale:** Studiare i log estratti da un'infrastruttura per comprendere come le caratteristiche dei pacchetti di rete influenzino la valutazione del rischio e le conseguenti azioni automatiche di difesa.
2. **La validazione dei dati sintetici:** Valutare l'efficacia di un Large Language Model nel generare dati artificiali. Nella cybersecurity, avere dati sintetici realistici è fondamentale per addestrare algoritmi di intelligenza artificiale o effettuare test senza esporre informazioni aziendali sensibili o violare le normative sulla privacy.

2 Obiettivi dell'Analisi Statistica

L'indagine statistica condotta sui dataset si sviluppa attraverso obiettivi ben definiti:

- **Esplorazione Monovariata e Bivariata:** Analizzare singolarmente le variabili principali, ovvero la lunghezza dei pacchetti e il punteggio di anomalia assegnato dai sistemi, verificandone la forma e l'eventuale presenza di anomalie o errori nel tracciamento.
- **Studio dell'Associazione e della Relazione Lineare:** Verificare, mediante indici di associazione e modelli di regressione, se esista un legame di causa-effetto lineare tra la dimensione del dato che transita nella rete e il punteggio di pericolosità assegnato.
- **Segmentazione Logica del Traffico:** Raggruppare le osservazioni in cluster con caratteristiche simili per identificare profili di traffico ricorrenti come ad esempio il traffico standard, anomalie isolate e attacchi massivi.
- **Certificazione del Dato Sintetico:** Confrontare le proprietà del dataset generato dall'LLM con quello reale mediante tecniche descrittive, verificando se l'intelligenza artificiale abbia appreso correttamente la struttura statistica sottostante.

3 Metodologia Statistica

Per raggiungere gli obiettivi prefissati, l'analisi si muove lungo tre analisi principali :

- **Analisi Descrittiva della Forma e Associazione:** Si utilizzano indici di posizione (Media, Mediana, Moda) per la tendenza centrale, e indici di associazione bivariata (Covarianza e Correlazione) per testare l'esistenza di un legame lineare tra le metriche quantitative.

- **Modellazione e Clustering:** Si applica il metodo dei Minimi Quadrati Ordinari (OLS) per stimare una retta di regressione e valutarne l'adattamento tramite lo studio dei residui. Successivamente, si impiega l'algoritmo K-Means per partizionare i dati in gruppi, basandosi sulla minimizzazione della distanza geometrica dai centroidi.
- **Verifica Inferenziale delle Ipotesi:** Si applica il Test del Chi-Quadrato in due formulazioni distinte: il test di indipendenza, per valutare la relazione tra variabili, e il test di buon adattamento, per verificare se il dataset sintetico ricalchi fedelmente il dataset reale.

4 Analisi Empirica e Risultati

4.1 Fase 1: Ispezione e Studio del Traffico Reale

La pipeline prende l'avvio con l'ispezione dei valori mancanti (NA). L'assenza di record nulli casuali conferma l'integrità strutturale del sistema di logging Fortigate.

4.2 4.1 Analisi Esplorativa dei Dati (EDA) su tutte le Variabili

L'Analisi Esplorativa dei Dati rappresenta la prima fase dell'analisi. L'obiettivo è caratterizzare la struttura distributiva, la dispersione e le proprietà di forma di tutte le colonne presenti nel dataset reale, distinguendo tra variabili quantitative continue e variabili qualitative categoriali.

4.2.1 4.1.1 Caratterizzazione Univariata delle Variabili Categoriali

Per comprendere la composizione del traffico e le decisioni operative intraprese dal sistema di sicurezza, l'analisi univariata è stata inizialmente condotta sulle due variabili qualitative del dataset: **Protocol** e **Action Taken**.

1. **Protocollo di Rete (Protocol):** Rappresenta la tipologia di protocollo di trasporto associata a ciascun log di rete. La distribuzione delle frequenze assolute e percentuali evidenzia la seguente composizione:

- **UDP:** Risulta il protocollo maggiormente rappresentato (oltre 1.000 log, pari a circa il 42% del totale), rispecchiando il traffico di streaming e risoluzione nomi basato su datagrammi leggeri.
- **TCP:** Costituisce la seconda componente per volume (circa 800 log, pari al 33%), relativo alle connessioni orientate allo stato (HTTP/HTTPS, SSH).
- **ICMP:** Rappresenta la quota minoritaria (circa 600 log, pari al 25%), associata ai messaggi di controllo e diagnostica di rete (es. richieste di PING).




Figure 1: Figura 4.1: Distribuzione delle frequenze assolute per i protocolli di rete (UDP, TCP, ICMP). Analisi univariata sulla variabile categoriale Protocol.

2. **Azione del Firewall (Action Taken):** Definisce la decisione di sicurezza applicata dal sistema al passaggio del pacchetto:

- **Logged:** Rappresenta la classe prevalente, indicando che la maggior parte delle transazioni è stata consentita e tracciata per monitoraggio di routine.
- **Blocked:** Evidenzia un volume significativo di eventi bloccati a causa del superamento delle soglie di pericolosità o di regole di policy restrittive.
- **Ignored:** Costituisce una frazione ridotta di eventi per i quali il firewall non ha intrapreso azioni attive.




Figure 2: Figura 4.2: Distribuzione delle frequenze assolute per le azioni intraprese dal firewall (Logged, Blocked, Ignored). Analisi univariata sulla variabile categoriale Action Taken.

4.2.2 4.1.2 Caratterizzazione Univariata delle Variabili Quantitative

Per le due metriche continue del dataset, **Packet Length** e **Anomaly Scores**, la caratterizzazione univariata ha previsto il calcolo sia degli indici di posizione centrale (Media, Mediana, Moda) sia degli indici di dispersione e forma (Deviazione Standard, Range Interquartilico IQR):

Table 1: Indici descrittivi sintetici per le variabili quantitative reali.

Variabile	Min	Q1	Mediana	Media	Q3	Max
Packet Length (Byte)	64	210	512	640.5	1024	1500
Anomaly Scores	0.0	25.0	50.0	49.8	74.5	100.0

- **Packet Length:** Presenta una distribuzione asimmetrica a destra e fortemente *multimodale* (evidenziata dall'istogramma di frequenza), con picchi in corrispondenza delle dimensioni standard dei pacchetti di controllo e del valore massimo MTU (1500 byte).
- **Anomaly Scores:** Presenta una copertura uniforme sull'intero intervallo $[0, 100]$. L'analisi mediante Boxplot mostra la perfetta simmetria della scatola interquartilica attorno alla mediana (prossima a 50) e l'assenza di outlier isolati rispetto ai baffi.

L'esame integrato di tutte e quattro le colonne del dataset garantisce la completa caratterizzazione esplorativa prima dell'applicazione dei modelli bivariati e di clustering.

L'analisi descrittiva univariata della variabile *Packet Length* evidenzia un comportamento estremamente interessante: la distribuzione non segue una forma a campana normale, ma si presenta nettamente multimodale. Come evidenziato nell'istogramma, la presenza di picchi ripetuti a frequenze specifiche riflette l'architettura stessa dei protocolli di rete, i quali

utilizzano dimensioni fisse standardizzate per i pacchetti di controllo e per il transito dei carichi utili (payload).




Figure 3: Distribuzione di frequenza empirica della lunghezza dei pacchetti di rete (Dati Reali).

Al contrario, lo studio della variabile *Anomaly Scores* mostra una distribuzione uniforme e ben bilanciata su tutto l'intervallo da 0 a 100. Il diagramma Boxplot conferma la perfetta simmetria della metrica e l'assoluta assenza di outlier cioè valori anomali isolati oltre, indicando che il sistema mappa il rischio in modo continuo e standardizzato.




Figure 4: Boxplot della dispersione del punteggio di anomalia nei log reali.

Per comprendere se la dimensione del pacchetto influenzi il punteggio di rischio, è stato tracciato uno scatterplot grezzo e calcolato il coefficiente di correlazione lineare di Pearson (r_{xy}). Il valore prossimo allo zero indica l'assenza di un legame lineare diretto: un pacchetto grande non è necessariamente più pericoloso di uno piccolo.




Figure 5: Scatterplot bivariato grezzo tra lunghezza pacchetto e punteggio di anomalia.

4.2.3 Test Chi-Quadrato di Indipendenza

Spostando l'attenzione sulle variabili qualitative, si è voluto verificare se il tipo di protocollo possa condizionare l'azione intrapresa dal sistema di sicurezza. Il test del Chi-Quadrato ha restituito un p-value pari a 0.8414. Poiché questo valore è nettamente superiore alla soglia critica classica ($\alpha = 0.05$), non possiamo dire che le due variabili siano correlate tra loro. Questo significa che le decisioni automatiche di blocco o monitoraggio vengono applicate in modo equo e uniforme, indipendentemente dal protocollo di trasporto utilizzato dal traffico.

4.2.4 Regressione Lineare e Validazione dei Residui

Per confermare l'assenza di relazioni lineari globali, è stato stimato un modello di regressione dei minimi quadrati (OLS). L'indice di determinazione D^2 nullo certifica che la variabilità della dimensione dei pacchetti non spiega la variazione dei punteggi di anomalia.

Tuttavia, l'aspetto più rilevante risiede nell'analisi grafica dei residui cioè le distanze tra i dati reali e la retta stimata. La nuvola dei residui si dispone formando una banda rettangolare perfettamente simmetrica e densa attorno alla linea dello zero, senza mostrare imbuto o pattern geometrici. Questo comportamento valida matematicamente il processo e dimostra che gli errori del modello sono puramente casuali e privi di distorsioni.




Figure 6: Grafico di dispersione dei residui sperimentali del modello di regressione.

4.2.5 Clustering Non Supervisionato via K-Means

L'assenza di una relazione lineare globale non esclude la presenza di sottogruppi locali nei dati. Per mappare queste relazioni è stato applicato l'algoritmo K-Means. La scelta del numero di gruppi (k) è stata guidata dallo Scree Plot, valutando la decrescita della varianza interna (WCSS).




Figure 7: Scree Plot della varianza intra-cluster (WCSS) al variare del numero di cluster.

Il grafico mostra un netto punto di flesso in corrispondenza di $k = 3$, indicando che dividere i dati in tre gruppi rappresenta il compromesso matematico ideale per massimizzare l'omogeneità interna e la separazione esterna.

L'algoritmo ha così isolato tre profili di traffico ben distinti nello spazio bivariato, come mostrato nello scatterplot colorato finale: il Cluster 1 identifica pacchetti piccoli con rischio bilanciato, il Cluster 2 intercetta pacchetti di grandi dimensioni, mentre il Cluster 3

raggruppa pacchetti di dimensioni medie. Questa segmentazione geometrica permette di semplificare l'analisi delle metriche di rete dividendo i log in categorie operative chiare.




Figure 8: Mappatura geometrica dello spazio dei log tramite partizionamento K-Means ($k = 3$).

4.3 Fase 2: Validazione e Confronto del Dataset Sintetico

La seconda parte del progetto si è focalizzata sulla validazione del dataset sintetico generato dall'LLM. Il confronto iniziale degli indici di sintesi (Minimo, Media, Massimi e Deviazioni Standard) mostra una corrispondenza tra le metriche reali e quelle artificiali.

Per analizzare visivamente l'allineamento distributivo, il boxplot di confronto affianca le distribuzioni degli score di anomalia. Le due scatole e l'estensione dei baffi risultano visivamente sovrapponibili, confermando che l'LLM ha replicato fedelmente i parametri di dispersione.




Figure 9: Boxplot comparativo della distribuzione degli Anomaly Scores.

4.3.1 Test Chi-Quadrato di Buon Adattamento

Per fornire una validazione inferenziale oggettiva, i punteggi continui di anomalia sono stati discretizzati in classi di frequenza equispaziate. Utilizzando le frequenze del dataset reale come base per calcolare le probabilità teoriche attese, è stato eseguito il test di buon adattamento del Chi-Quadrato sul dataset sintetico.

Il test ha confermato che le discrepanze tra le frequenze generate dall'LLM e quelle attese dal modello reale sono statisticamente irrilevanti. L'intelligenza artificiale ha superato la validazione, dimostrandosi in grado di produrre dati sintetici matematicamente indistinguibili dalla popolazione reale e pronti per l'uso in contesti di simulazione sicura.

5 Conclusioni e Discussione

L'applicazione delle tecniche statistiche ha permesso di completare con successo l'analisi dello scenario Fortigate. Lo studio ha dimostrato l'imparzialità dei sistemi di sicurezza rispetto ai protocolli di rete, ha escluso la presenza di relazioni lineari ingannevoli e ha isolato tre profili geometrici di traffico grazie al clustering K-Means, ottimizzato analiticamente tramite lo Scree Plot.

La validazione inferenziale condotta nella seconda fase ha certificato la qualità del dataset sintetico. L'esito positivo del test del Chi-Quadrato di buon adattamento garantisce la possibilità di adottare i dati simulati per l'addestramento e il testing delle infrastrutture di cybersecurity, eliminando i rischi di data leakage e garantendo la piena aderenza metodologica alle richieste degli standard scientifici.